

Llegando de Excel a R para epidemiólogos

Taller: De Excel a R

Overview

La formación especializada en el lenguaje de programación R aporta habilidades para iniciar en la denominada ciencia de datos con aplicación directa a la práctica profesional. Además es una herramienta gratuita de código abierto en continua innovación/actualización por parte de la comunidad científica. La versatilidad de R para procesar datos y obtener resultados en diversas campos del análisis de datos lo hace un software de elección en diversas áreas de conocimiento como medicina y ciencias de la salud, financiera, investigación científica, epidemiología, ciencias sociales, economía entre muchas otras, en las que es necesario la implementación de potentes analíticas como modelamiento matemático y estadístico, análisis geoespaciales, machine learning, inteligencia artificial y visualización de datos, con la gran ventaja de nunca perder la transparencia y reproducibilidad del resultado.

Cada vez es más evidente la necesidad de que los profesionales adopten lenguajes de programación para sus procesos de análisis de datos, aprovechando las ventajas que ofrecen en términos de reproducibilidad, transparencia y eficiencia. En este contexto, las hojas de cálculo, como las de Microsoft Excel, han ocupado un lugar central por su disponibilidad y facilidad de uso, convirtiéndose en una herramienta clave para el tratamiento de datos entre epidemiólogos, salubristas y otros profesionales dedicados a la vigilancia en salud pública. Este avance ha sido significativo para el manejo de información.

Sin embargo, el uso de hojas de cálculo comienza a mostrar limitaciones importantes: las tareas repetitivas de depuración y análisis consumen gran cantidad de tiempo, y la falta de integración con nuevas herramientas dificulta la reproducibilidad y sostenibilidad en el tiempo. Ante este panorama, surgen alternativas como R, que ofrece notables ventajas al profesional gracias a su naturaleza de software libre, programable y altamente reproducible. Si bien exige un aprendizaje inicial más riguroso, los beneficios que aporta superan con creces estas barreras.

Por ello, en distintas partes del mundo han surgido iniciativas para promover a R como la plataforma de referencia, de modo que epidemiólogos y profesionales de la salud puedan in-

tegrarlo en sus rutinas de trabajo y avanzar hacia un lenguaje común de análisis en salud pública.

i Note

Modalidad: Taller teórico-práctico

Duración: 2 días (8 h/día)

Cupo: 30 participantes

Día 1 — Fundamentos y primeras transformaciones

Objetivo: Crear confianza en R, comprender la lógica de proyectos, scripts y estructuras de datos, y realizar primeras operaciones comparando con Excel.

Cronograma

Hora	Sesión
08:00 – 08:30	Apertura: presentación del curso, objetivos, agenda; expectativas.
08:30 – 09:30	Organización de un proyecto en R: RStudio, carpetas, buenas prácticas. <i>Mini-evaluación:</i> crear proyecto y script.
09:30 – 11:00	El script para reproducibilidad: crear, guardar, comentar, ordenar. <i>Ejercicio:</i> script con apartados básicos.
11:00 – 11:15	Pausa café
11:15 – 12:30	Estructuras básicas: vectores, data frames, listas; paralelos con Excel. <i>Evaluación:</i> crear vector y data frame “tipo hoja de cálculo”.
12:30 – 13:30	Almuerzo
13:30 – 15:00	Importar y exportar datos: Excel/CSV/TXT; <i>práctica:</i> importar varios datasets.
15:00 – 16:30	Introducción al tidyverse: filosofía, operador %>%, primeras verbos dplyr.
16:30 – 16:45	Pausa
16:45 – 18:00	Seleccionar, filtrar y ordenar (básico): select, filter, arrange; operadores lógicos/booleanos;

Resultados de aprendizaje del Día 1

- Estructurar un proyecto en RStudio.

- Escribir scripts reproducibles y ordenados.
- Importar/exportar datos tabulares.
- Aplicar verbos básicos de `dplyr`.

Día 2 — Transformación, limpieza y análisis práctico

Objetivo: Aplicar transformaciones intermedias, depurar datos, unir tablas y generar salidas resumidas útiles para vigilancia en salud.

Inicio: *Evaluación corta de arranque* (abrir R, proyecto y script del día 1).

Cronograma

Hora	Sesión
08:00 – 09:30	Crear y transformar (básico–intermedio): <code>mutate</code> , <code>case_when</code> ; <i>evaluación:</i> variable categórica y conversión texto numérico.
09:30 – 10:30	De-duplicación y texto: <code>distinct</code> ; limpieza con <code>stringr</code> (<code>str_to_lower</code>); depurar nombres de municipios/instituciones.
10:30 – 10:45	Pausa
10:45 – 12:15	Columnas: <code>separate</code> , <code>unite</code> ; <i>evaluación:</i> normalización de variable.
12:15 – 13:15	Almuerzo
13:15 – 15:45	Uniones: <code>bind_rows</code> , <code>bind_cols</code> , <code>left_join</code> , <code>inner_join</code> ; <i>evaluación:</i> unir dos tablas y verificar consistencia.
15:45 – 16:00	Pausa
16:00 – 17:15	Tablas dinamicas con tidy: <code>group_by</code> , <code>summarise</code>
17:15 – 18:00	Cierre: retroalimentación grupal.

Resultados de aprendizaje del Día 2

- Diseñar pipelines de limpieza y transformación.
- Unir y reestructurar datasets.
- Generar tablas resumen para decisiones rápidas.

Evaluaciones y dinámica

- **Prácticas guiadas** con datos tipo vigilancia en salud.
- **Producto final:** script reproducible con todo el flujo trabajado.

Tip

Sugerencia de pre-requisitos

Instalar R y RStudio, y tener permisos para leer/escribir en la carpeta de trabajo.

Es este curso para mí?

Si su respuesta a cualquiera de la siguientes es “Sí”, luego este es el lugar correcto para iniciar a desarrollar habilidades .

- Requiere procesar datos descriptivos en el ambito de la vigilancia en salud pública que incluyen tareas de depuracion o pre-procesamiento?
- Requiere un flujo de trabajo con datos, repetitivo (diario, semanal, mensual)?
- Hasta el momento continua usando hojas de calculo como único medio para el procesamiento de datos limitando su capacidad de implementar analíticas distintas en su trabajo?

Este curso esta diseñado para quienes no tienen ninguna experiencia con R-Software y RStudio pero si tienen contacto con datos epidemiologicos y altas necesidades en su implementación dentro su flujo trabajo diario.

Previo

Para este curso debe tener un computador portatil personal o institucional pero que permita la instalación de software libre sin restricción o necesidades de claves de administrador.

Instructor principal



Jorge Mario Estrada A. es Lic. Matemáticas y Epidemiólogo de Campo (FETP), PhD. en Estadística Matemática y Aplicada en la Universidad de Granada y Maestrías en Epidemiología y Estadística Aplicada. Sus intereses en investigación incluyen, Implementación de métodos estadísticos para Epidemiología e investigación clínica, Epidemiología de enfermedades infecciosas, Ciencia de datos aplicada a Salud Pública, Métodos de estimación para prevalencias bajas de enfermedades/infecciones.

Apasionado por el Ciclomontañismo (modalidad de Marathon) y en la modalidad Gravel (Bikepacking, Carreras Gravel larga distancia).